

SLOVENSKÁ TECHNICKÁ UNIVERZITA V BRATISLAVE

Fakulta elektrotechniky a informatiky

3D Gaussian Splatting

Študijný program:	robotika a kybernetika
Študijný odbor:	kybernetika
Školiace pracovisko:	ústav robotiky a kybernetiky
Predmet:	počítačové videnie a spracovanie obrazu
Zadanie vypracoval:	Dominik Kupec a Martin Brandobur

28.4.2026

Bratislava

Obsah

1	Zadanie	3
1.1	Úlohy.....	3
2	Vypracovanie	5
2.1	Model z internetu – bicycle.....	5
2.1.1	Použitá štruktúra	5
2.1.2	Funkčný tréningový príkaz	5
2.1.3	Výsledky – bicycle.....	5
2.1.4	Screenshoty	6
2.2	Vlastný model – Autíčko.....	8
2.2.1	Príprava dát	9
2.2.2	COLMAP postup	10
2.2.3	Kľúčová oprava workflow	10
2.2.4	Finálny tréningový príkaz	10
2.2.5	Výsledky – autíčko.....	10
2.2.6	Porovnanie s pôvodným starším úspešným behom autíčka.....	11
2.2.7	Screenshoty – autíčko	12
3	Porovnanie modelov z internetu a vlastného	15
4	Grafické porovnanie	16
5	Záver	18

1 Zadanie

Cieľom zadania je oboznámiť sa s modernou metódou 3D rekonštrukcie scény pomocou 3D Gaussian Splatting (3DGS). Študent prejde celým pracovným postupom od fotografií až po interaktívny 3D viewer, najprv na referenčnom datasete a potom na vlastnoručne nasnímanej scéne.

Zadanie je dokopy za **25 b.** a pozostáva z nasledujúcich úloh:

1.1 Úlohy

1. [5 b.] Spustenie postupu na referenčnom datasete.

Tato úloha slúži na **pochopenie celého pracovného postupu** a overenie funkčnosti prostredia ešte pred tým, ako budete pracovať na vlastnom datasete. Na referenčných dátach sa naučíte každý krok

bez toho, aby ste riešili problémy so snímaním.

Stiahnite niektorý z verejne dostupných datasetov (napr. *Tanks and Temples – truck, garden*, alebo iný kompatibilný dataset). Z datasetu použite **iba fotografie** (adresár input/) – *žiadne prepočítane dáta*. Celý postup spustíte sami od začiatku podľa návodu NAVOD.md:

- a) `./run.sh` – spustenie Docker kontajnera.
- b) `colmap gui` – spustenie COLMAP GUI a postupne vykonanie:
 - Feature extraction (model: SIMPLE_PINHOLE)
 - Feature matching (Exhaustive)
 - Reconstruction (Sparse)
 - Export modelu do `distorted/sparse/0/`
- c) `python3 convert.py -s data/<dataset>` – undistortion fotografií.
- d) `python3 train.py -s data/<dataset>` – trenovanie 3DGS modelu (30 000 iterácií, checkpointy po 7 000 a 30 000).
- e) `SIBR_gaussianViewer_app -m output/<uuid>` – vizualizácia výsledku.

Zdokumentujte postup screenshotmi z každého kroku (COLMAP GUI, priebeh tréningu, viewer). Uveďte dosiahnutú metriku PSNR po 7 000 a 30 000 iteráciách.

2. [10 b.] Snímanie vlastnej scény kamerou Ximea.

Vyberte a nasnímate vlastnú scénu priemyselnou kamerou Ximea (vysoké rozlíšenie). Fotografie **downscalujte** pred spustením COLMAP (odporúčame dlhšiu stranu na max. **600–1200 px**) – kamera má príliš vysoké rozlíšenie na priame spracovanie a zároveň COLMAP

aj 3DGS by bežali neúnosne dlho. Spustíte celý postup rovnako ako v úlohe 1. Uved'te dosiahnutú metriku PSNR a vizuálne porovnajte výsledok s referenčným datasetom.

3. [5 b.] Vyhodnotenie výsledkov.

Porovnajte výsledky oboch scén (referenčný dataset vs. vlastná scéna):

- tabuľka PSNR po 7 000 a 30 000 iteráciách,
- vizuálne porovnanie renderov z rovnakých uhlov pohľadu,
- komentár – čo ovplyvnilo kvalitu vlastnej scény (počet fotografií, osvetlenie, typ objektu, . . .).

4. [5 b.] Dokumentácia.

Odovzdajte správu (PDF) obsahujúcu:

- popis každého kroku s príslušnými screenshotmi,
- popis procesu snímania vlastnej scény (čo, kde, ako),
- grafické porovnanie výsledkov,
- záver s odporúčeniami – čo by ste urobili inak pre lepšie výsledky.

Termín odovzdania: 12. cvičenie semestra

2 Vypracovanie

2.1 Model z internetu – bicycle

Pre prvú časť zadania bol použitý pripravený dataset bicycle. Tento dataset už obsahoval vstupné obrázky aj COLMAP sparse model, preto nebolo potrebné robiť vlastný COLMAP workflow ani používať `convert.py`.

2.1.1 Použitá štruktúra

- `/opt/gaussian-splatting/PVSO/Fotky_bicykel/bicycle`
- `/opt/gaussian-splatting/PVSO/Bike_Gaussian`

2.1.2 Funkčný tréningový príkaz


- `python3 train.py -s PVSO/Fotky_bicykel/bicycle -m PVSO/Bike_Gaussian -r 8 --densify_until_iter 5000`

2.1.3 Výsledky – bicycle


Metrika	Iterácia 7000	Iterácia 30000
PSNR	27.167381286621094	29.62764587402344

Tréning úspešne dobehol do 30000 iterácií a výsledný model bol uložený do `PVSO/Bike_Gaussian`.

2.1.4 Screenshots



Obrázok 1 COLMAP - bicycle



Obrázok 2 Feature matching - bicycle

Feature extraction (on cdb607db703b)

Camera model

SIMPLE_PINHOLE

Parameters: f, cx, cy

☒ Shared for all images
☐ Shared per sub-folder
☒ Parameters from EXIF
☐ Custom parameters

Extract

Import

mask_path

Select folder

camera_mask_path

Select file

max_image_size

3200

max_num_features

8192

first_octave

-1

num_octaves

4

octave_resolution

3

peak_threshold

0.00667

edge_threshold

10.00

estimate_affine_shape

☐

max_num_orientations

2

upright

☐

domain_size_pooling

☐

dsp_min_scale

0.16667

dsp_max_scale

3.00000

dsp_num_scales

10

num_threads

-1

use_gpu

☒

gpu_index

-1

Extract

Obrázok 3 Feature extraction - bicycle

```

Output folder: PVS0/Bike_Gaussian [22/04 10:43:47]
Tensorboard not available: not logging progress [22/04 10:43:47]
Reading camera 194/194 [22/04 10:43:47]
Loading Training Cameras [22/04 10:43:47]
Loading Test Cameras [22/04 10:44:13]
Number of points at initialisation : 54275 [22/04 10:44:13]
Training progress: 23%| | 7000/30000 [07:02<36:05, 10.62it/s, Loss=0.0507206, D
[ITER 7000] Evaluating train: L1 0.027070195227861405 PSNR 27.167381286621094 [2
2/04 10:51:16]

[ITER 7000] Saving Gaussians [22/04 10:51:16]
Training progress: 100%|█| 30000/30000 [43:05<00:00, 11.60it/s, Loss=0.0387897,

[ITER 30000] Evaluating train: L1 0.01985426936298609 PSNR 29.62764587402344 [22
/04 11:27:19]

[ITER 30000] Saving Gaussians [22/04 11:27:19]

Training complete. [22/04 11:27:40]
root@cdb607db703b:/opt/gaussian-splatting# █


```

Obrázok 4 Tréning - bicycle

2.2 Vlastný model – Autíčko

Pri druhej časti zadania boli použité vlastné fotografie modelu autíčka. Obrázky boli pred spracovaním zmenšené na rozmer 960 x 1280 px, aby COLMAP aj tréning bežali rozumne rýchlo. Autíčko som fotil tak, že zostalo položené na jednom mieste a ja som ho postupne obchádzal kamerou zo všetkých strán. Fotografie som robil dookola v kruhovej trajektórii, pričom som zachytil prednú, zadnú, bočné aj šikmé pohľady a zároveň aj mierne pohľady zhora, aby bolo vidieť aj strechu a horné časti karosérie. Medzi jednotlivými snímkami som nechával dostatočný prekryt, aby COLMAP vedel nájsť spoločné body medzi fotografiami. Celkovo som vytvoril **157 fotografií**, z ktorých COLMAP úspešne určil polohy kamier a vytvoril riedku 3D rekonštrukciu s približne **36 020 bodmi**.

Fotografie boli zmenšené z pôvodného rozlíšenia **3024 × 4032 px** na **960 × 1280 px**, pretože toto rozlíšenie zachováva rovnaký pomer strán **3:4** ako pôvodné snímky. Vďaka tomu nedošlo k deformácii ani orezaniu obrazu. Zároveň sa výrazne znížila veľkosť dát a zrýchlilo spracovanie v COLMAPe aj trénovanie Gaussian Splatting modelu. Rozlíšenie **900 × 600 px** nebolo vhodné, pretože má iný pomer strán **3:2**, spôsobilo by stratu časti obrazu alebo deformáciu a zároveň by obsahovalo menej detailov potrebných na kvalitnú rekonštrukciu.



Obrázok 5 Metadáta z kamery (rozlíšenie pred resize)

2.2.1 Príprava dát

- `/opt/gaussian-splatting/data/auticko_3/input`
- `/opt/gaussian-splatting/data/auticko_3/distorted/sparse/0`

Počet použitých snímok bol 159. V COLMAPe bol vytvorený projekt s databázou `data/auticko_3/database.db` a s cestou projektu do `data/auticko_3/distorted/sparse/0/project.ini`.

2.2.2 COLMAP postup

- File -> New project
 - Processing -> Feature extraction
 - Camera model: SIMPLE_PINHOLE
 - Shared for all images: ON
 - Parameters from EXIF: ON
 - Processing -> Feature matching -> Exhaustive
 - Reconstruction -> Start reconstruction
- Správny model nebol malý 6- alebo 7-image model, ale model v priečinku distorted/sparse/1. Overenie cez model_analyzer ukázalo 157 registrovaných snímok, 35814 bodov a mean reprojection error 0.429195 px. Tento model bol následne použitý ako finálny model v distorted/sparse/0.

2.2.3 Kľúčová oprava workflow

Pri autíčku vznikol problém v tom, že obyčajné spustenie convert.py vybralo nesprávny malý model so 6 až 7 obrázkami. Riešením bolo ponechať správny model v data/auticko_3/distorted/sparse/0 a použiť convert.py s parametrom --skip_matching, aby sa neprepočítaval nový chybný COLMAP model.

- `python3 convert.py -s data/auticko_3 --skip_matching`

2.2.4 Finálny tréningový príkaz

- `python3 train.py -s data/auticko_3 -m PVSO/Auticko_Gaussian`

Pri tomto behu bolo načítaných 157 kamier a pri inicializácii bolo 37737 bodov, čo potvrdilo, že tréning už používa správny dataset.

2.2.5 Výsledky – autíčko

Metrika	Inicializácia	Iterácia 7000	Iterácia 30000
Kamery / body / PSNR	157 kamier / 37737 bodov	26.154316711425782	29.215924453735354


Tréning úspešne dobehol do 30000 iterácií a výstupný model bol uložený do PVSO/Auticko_Gaussian.

2.2.6 Porovnanie s pôvodným starším úspešným behom autíčka


Beh	PSNR 7000	PSNR 30000
Pôvodný beh z Postup.md	26.74098815917969	29.796587371826174
Aktuálny finálny rerun	26.154316711425782	29.215924453735354

Aktuálny rerun dosiahol mierne nižšie PSNR než pôvodný starší beh, ale workflow je teraz presne zdokumentovaný a reprodukovateľný.


2.2.7 Screenshots – autíčko



Obrázok 6 COLMAP - autíčko



Obrázok 7 Feature extraction – autíčko



Obrázok 8 Feature matching – autíčko

```
Done.
Optimizing
Output folder: ./output/512a32f1-c [21/04 22:07:17]
Tensorboard not available: not logging progress [21/04 22:07:17]
Reading camera 157/157 [21/04 22:07:17]
Converting point3d.bin to .ply, will happen only the first time you open the scene. [21/04 22:07:17]
Loading Training Cameras [21/04 22:07:17]
Loading Test Cameras [21/04 22:07:21]
Number of points at initialisation : 36020 [21/04 22:07:21]
Training progress: 23%|██████████| 7000/30000 [08:56<33:41, 11.38it/s, Loss=0.0702534, Depth Loss=0.0000000]
[ITER 7000] Evaluating train: L1 0.03203583508729935 PSNR 26.74098815917969 [21/04 22:16:18]

[ITER 7000] Saving Gaussians [21/04 22:16:18]
Training progress: 100%|██████████| 30000/30000 [50:22<00:00, 9.92it/s, Loss=0.0319942, Depth Loss=0.0000000]

[ITER 30000] Evaluating train: L1 0.022360565513372423 PSNR 29.796587371826174 [21/04 22:57:44]

[ITER 30000] Saving Gaussians [21/04 22:57:44]

Training complete. [21/04 22:57:46]
root@dominik-Legion-Pro-5-16IRX9:/opt/gaussian-splatting#
```


Obrázok 9 Tréning - autíčko

3 Porovnanie modelov z internetu a vlastného


Model	Vstup	PSNR 7000	PSNR 30000
bicycle	pripravený dataset z internetu	27.167381286621094	29.62764587402344
Auticko_3	vlastné fotografie, COLMAP + skip_matching	26.154316711425782	29.215924453735354

Model z internetu dosiahol mierne lepšie PSNR, čo je očakávané, pretože ide o pripravený benchmarkový dataset s veľmi dobrým coverage a konzistentnými dátami. Vlastný model autička je napriek tomu úspešný a vhodný na demonštráciu celého pipeline na vlastných dátach.


4 Grafické porovnanie




Obrázok 10 Porovnanie 7000 vs 30 000 iterácií – bicycle pred



Obrázok 11 Porovnanie 7000 vs 30 000 iterácií – bicycle zad



Obrázok 12 Porovnanie 7000 vs 30 000 iterácií – auticko



Obrázok 13 Porovnanie 7000 vs 30 000 iterácií – auticko (scale 0.001)

5 Záver

V rámci zadania bol úspešne realizovaný celý postup 3D rekonštrukcie scény pomocou metódy 3D Gaussian Splatting. Najskôr bol spracovaný referenčný dataset bicycle, na ktorom sa overila funkčnosť pracovného prostredia. Tento model dosiahol PSNR 27,17 po 7000 iteráciách a 29,63 po 30000 iteráciách. Následne bol rovnaký postup aplikovaný aj na vlastný dataset autíčka, ktorý bol vytvorený z vlastnoručne nasnímaných fotografií. Po úprave rozlíšenia, spracovaní v COLMAPe a oprave workflow pomocou parametra `--skip_matching` sa podarilo získať použiteľnú rekonštrukciu s 157 registrovanými kamerami a desiatkami tisíc bodov. Vlastný model dosiahol PSNR 26,15 po 7000 iteráciách a 29,22 po 30000 iteráciách.

Z porovnania výsledkov vyplýva, že referenčný dataset dosiahol mierne lepšie hodnoty PSNR, čo je očakávané vzhľadom na jeho kvalitnejšiu prípravu, lepšie pokrytie scény a konzistentnejšie vstupné dáta. Vlastný model autíčka však dosiahol veľmi podobné výsledky a potvrdil, že 3D Gaussian Splatting je možné úspešne použiť aj na vlastnoručne nasnímané dáta. Kvalitu vlastnej rekonštrukcie ovplyvnilo najmä osvetlenie, počet a rozmiestnenie fotografií, prekryt medzi snímkami, lesklé časti objektu a výrazná textúra podložky. Pri vizuálnom porovnaní bolo vidieť, že výsledok po 30000 iteráciách bol ostrejší a stabilnejší ako po 7000 iteráciách, najmä pri detailoch objektu a okolitého povrchu.

Pre dosiahnutie lepších výsledkov by bolo vhodné pri ďalšom meraní použiť rovnomernejšie osvetlenie, stabilnejšiu kruhovú trajektóriu snímania a väčší počet fotografií z rôznych výšok. Pomohlo by tiež obmedziť odlesky na objekte, použiť matnejšie pozadie a zabezpečiť, aby boli všetky časti objektu zachytené z viacerých uhlov s dostatočným prekrytím. Celkovo zadanie ukázalo, že kvalita vstupných fotografií a správne nastavený COLMAP workflow majú zásadný vplyv na finálnu kvalitu 3DGS modelu.